

ME315 - Laboratório 02: Processamento de Bases de Dados em Lote

João Augusto Zaffalon

Questão 1

Quais são as estatísticas suficientes para a determinação do percentual de voos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

Resposta: As estatísticas suficientes são o número total de voos com atraso superior a 10 minutos e o número total de voos. Com essas duas contagens parciais de cada lote, é possível calcular o percentual total no final.

Questão 2

Crie uma função chamada `getStats` que, para um conjunto de dados, filtre as observações das Cias. Aéreas de interesse, remova valores faltantes, agrupe por dia, mês e cia. aérea, e retorne as estatísticas suficientes.

```
getStats <- function(input, pos) {  
  input %>%  
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
    filter(!is.na(AIRLINE), !is.na(ARRIVAL_DELAY), !is.na(YEAR), !is.na(MONTH), !is.na(DAY))  
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%  
    summarise(  
      n_atraso = sum(ARRIVAL_DELAY > 10),  
      n_total = n(),  
      .groups = "drop"  
    )  
}
```

Questão 3

Utilize a função `readr::read_csv_chunked` para importar o arquivo `flights.csv.zip` em lotes de 100 mil registros, aplicando a função de callback `getStats`.

```
cols_interesse <- cols_only(  
  YEAR = col_integer(),  
  MONTH = col_integer(),  
  DAY = col_integer(),  
  AIRLINE = col_character(),  
  ARRIVAL_DELAY = col_double()  
)  
  
estatisticas_lote <- read_csv_chunked(  
  file = "flights.csv.zip",  
  callback = DataFrameCallback$new(getStats),  
  chunk_size = 100000,  
  col_types = cols_interesse  
)
```

Questão 4

Crie uma função chamada `computeStats` que combine as estatísticas suficientes para compor a métrica final e retorne um tibble com as colunas `Cia`, `Data` e `Perc`.

```
computeStats <- function(base) {  
  base %>%  
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%  
    summarise(  
      total_atraso = sum(n_atraso),  
      total_voos = sum(n_total),  
      .groups = "drop"  
    ) %>%  
    mutate(  
      Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-")),  
      Perc = total_atraso / total_voos  
    ) %>%  
    select(Cia = AIRLINE, Data, Perc)  
}  
  
stats_finais <- computeStats(estatisticas_lote)
```

Questão 5

Produza um mapa de calor em formato de calendário para cada Cia. Aérea utilizando o pacote ggcal.


```
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  sub <- stats %>% filter(Cia == cia)
  # Correção aqui: removido x= e y=
  ggcal(sub$Data, sub$Perc)
}

cAA <- baseCalendario(stats_finais, "AA")
cDL <- baseCalendario(stats_finais, "DL")
cUA <- baseCalendario(stats_finais, "UA")
cUS <- baseCalendario(stats_finais, "US")


cAA + pal + ggtitle("AA")
```

AA




```
cDL + pal + ggtitle("DL")
```

DL




```
cUA + pal + ggtitle("UA")
```

UA



```
cUS + pal + ggtitle("US")
```

US



Data e Hora de Compilação

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-24 22:56:13 -03"
```